

银行信用卡欺诈与拖欠行为分析

- (1) 加深对数据的理解，从应用背景出发对获取的各个原始信息进行理解，包括每个变量表示的含义以及相应的变量说明；
- (2) 加深对数据准备的理解，很多的原始信息并不能直接用于数据分析，需要对之进行各种变换才能提取出对数据分析有使用价值的变量，掌握数据的各种复杂变换方法；
- (3) 理解和掌握模型的建立过程，根据业务场景及其可以使用的数据，建立聚类、决策树和关联规则等多个挖掘模型。

实验要求：根据业务场景及其可以使用的数据，建立聚类、决策树和关联规则等多个挖掘模型。

➤ 按照关键词“客户号”合并“申请客户信息”和“客户信用记录”两个表格，并删除重复字段

表格 (21 个字段, 10,000 条记录)																	
文件(E) 编辑(E) 主成(S)																	
表格 注解																	
客户号	客户姓名	证件号码	年龄	性别	婚姻状态	教育程度	职业类别	户籍	居住类型	车辆情况	保险缴纳	工作年限	个人年收入	信贷情况	年龄_连续	个人收入_连续	信用总评分_值
1	0000999941960814	王颖丽	469127****04051074	45	女	未婚	本科	私营企业	海南	租房	无	有	22,000 10000	没有贷款记录	\$null\$	\$null\$	\$null\$ \$null\$
2	0000999941967060	于星	510095****07264140	21	男	未婚	大专	外资企业	四川	租房	无	无	1,000 10000	没有贷款记录	\$null\$	\$null\$	\$null\$ \$null\$
3	0000999941980401	何伦军	123355****08034986	22	女	未婚	大专	私营企业	天津	租房	无	无	2,000 10000	没有贷款记录	\$null\$	\$null\$	\$null\$ \$null\$
4	0000999963835873	唐晋西	318268****05122232	25	男	未婚	本科	个体户	上海	租房	有	有	2,000 5700000000	现在没有贷款	25,000 5700000000	86,000 B-F	\$null\$ \$null\$
5	0000999973835875	鲍理	542433****03107248	25	男	未婚	本科	私营企业	西藏	自购房	有	有	2,000 6800000000	正常还款	25,000 6800000000	90,000 A-F	\$null\$ \$null\$
6	0000999983959391	阎飞飞	365607****07132924	25	女	未婚	本科	私营企业	江西	租房	有	有	2,000 9900000000	正在还贷	25,000 9900000000	86,000 B-F	\$null\$ \$null\$
7	0000999983959392	阎飞飞	614314****11089676	32	男	未婚	本科	私营企业	陕西	租房	无	有	9,000 9900000000	现在没有贷款	32,000 9900000000	84,000 B-F	\$null\$ \$null\$
8	0000999983959393	李莲	132909****11072577	52	女	未婚	本科	私营企业	河北	租房	无	有	29,000 9900000000	正常还款	52,000 9900000000	87,000 B-F	\$null\$ \$null\$
9	0000999983984984	李呈瓜	427981****08076473	32	男	未婚	大专	私营企业	湖北	租房	无	无	12,000 10000	没有贷款记录	\$null\$	\$null\$	\$null\$ \$null\$
10	0000999984412439	舒付星	501858****12251141	41	女	已婚	本科	个体户	重庆	租房	无	有	18,000 10000	没有贷款记录	\$null\$	\$null\$	\$null\$ \$null\$
11	0000999993800103	文站峰	502231****10099197	56	男	未婚	大专	私营企业	重庆	其他	无	无	36,000 10000	没有贷款记录	\$null\$	\$null\$	\$null\$ \$null\$
12	0000999993800114	叶析	501948****01293931	33	男	未婚	高中	个体户	重庆	租房	无	无	15,000 10000	没有贷款记录	\$null\$	\$null\$	\$null\$ \$null\$
13	0000999993800125	周惠振	516416****08306383	34	男	未婚	本科	国有企业	四川	租房	无	有	11,000 10000	没有贷款记录	\$null\$	\$null\$	\$null\$ \$null\$
14	0000999993800136	仇雷	451519****03287759	35	男	已婚	本科	私营企业	广西	其他	无	有	12,000 10000	没有贷款记录	\$null\$	\$null\$	\$null\$ \$null\$
15	0000999993800147	谈李曲	313972****11181266	36	男	未婚	初中及	私营企业	上海	其他	无	无	22,000 10000	没有贷款记录	\$null\$	\$null\$	\$null\$ \$null\$
16	0000999993800158	姚国干	640523****10189997	31	女	已婚	高中	外资企业	宁夏	租房	无	无	13,000 10000	还在拖欠	\$null\$	\$null\$	\$null\$ \$null\$
17	0000999993800169	张伟	460018****03147804	42	女	已婚	初中及	私营企业	海南	其他	无	有	14,000 10000	还在拖欠	\$null\$	\$null\$	\$null\$ \$null\$
18	0000999993800170	王伟	366603****05282009	29	男	未婚	高中	外资企业	江西	租房	无	无	11,000 10000	没有贷款记录	\$null\$	\$null\$	\$null\$ \$null\$
19	0000999993800181	王芳	622050****05158423	23	男	未婚	高中	私营企业	甘肃	租房	无	无	5,000 10000	没有贷款记录	\$null\$	\$null\$	\$null\$ \$null\$
20	0000999993800192	李伟	340003****10014310	28	男	已婚	大专	国有企业	安徽	租房	无	无	8,000 10000	没有贷款记录	\$null\$	\$null\$	\$null\$ \$null\$
21	0000999993800205	万恩	539518****12026672	55	女	已婚	本科	私营企业	贵州	租房	有	有	32,000 10192	没有贷款记录	\$null\$	\$null\$	\$null\$ \$null\$
22	0000999993800216	邢炎娟	431851****10317891	24	男	未婚	本科	个体户	湖南	租房	有	有	1,000 10192	没有贷款记录	\$null\$	\$null\$	\$null\$ \$null\$
23	0000999993800227	景飞蒙	647096****101026247	23	男	未婚	本科	私营企业	宁夏	自购房	有	有	0,000 10192	现在没有贷款	\$null\$	\$null\$	\$null\$ \$null\$
24	0000999993800238	韦奇迪	365596****10055089	24	男	未婚	本科	国有企业	江西	租房	有	有	1,000 10192	现在没有贷款	\$null\$	\$null\$	\$null\$ \$null\$
25	0000999993800249	高金怡	657797****12310192	28	男	未婚	本科	私营企业	新疆	租房	无	有	5,000 10192	现在没有贷款	\$null\$	\$null\$	\$null\$ \$null\$
26	0000999993800250	吕丛琳	213160****08027459	24	女	未婚	初中及	私营企业	辽宁	租房	无	无	13,000 10280	逾期还款	\$null\$	\$null\$	\$null\$ \$null\$
27	0000999993800261	耿彬雷	210705****04165516	26	男	未婚	初中及	其他企业	辽宁	其他	无	无	9,000 10280	逾期还款	\$null\$	\$null\$	\$null\$ \$null\$
28	0000999993800272	陆世宁	527503****04187789	27	男	未婚	高中	私营企业	上海	租房	无	无	9,000 10280	逾期还款	\$null\$	\$null\$	\$null\$ \$null\$
29	0000999993800283	谢海强	537938****03050636	38	男	未婚	高中	私营企业	上海	租房	无	无	20,000 10280	还在拖欠	\$null\$	\$null\$	\$null\$ \$null\$
30	0000999993800294	武寒英	442294****04238956	45	男	未婚	大专	外资企业	广东	租房	无	有	25,000 10280	还在拖欠	\$null\$	\$null\$	\$null\$ \$null\$
31	0000999993800307	原香阳	431730****07148897	28	男	未婚	大专	私营企业	湖南	租房	无	无	8,000 10294	逾期还款	\$null\$	\$null\$	\$null\$ \$null\$
32	0000999993800318	王婉南	641712****06026762	35	男	未婚	硕士及	私营企业	宁夏	租房	无	有	10,000 10294	逾期还款	\$null\$	\$null\$	\$null\$ \$null\$
4																	

- 填充没有值的字段：没通过审批用户信用总评分设为 0，信用等级设为“F-未通过客户”，额度为 0，审批结果为“1-未通过”

填充

预览(P)

设置 注解

填入字段:

信用等级

替换: 空值

条件:

1 @BLANK(@FIELD)

替换为:

1 "F-未通过用户"

确定 取消 应用(A) 重置(R)

填充

预览(P)

设置 注解

填入字段:

信用总评分

额度

替换: 空值

条件:

1 @BLANK(@FIELD)

替换为:

1 0

确定 取消 应用(A) 重置(R)

填充

预览(P)

设置 注解

填入字段:

审批结果

替换: 空值

条件:

1 @BLANK(@FIELD)

替换为:

1 "1-未通过"

确定 取消 应用(A) 重置(R)

- 使用“过滤器”过滤“客户号”“客户姓名”等标识变量以及“额度”“信用总评分”等与“信用等级”重复意思变量

过滤器

预览(P)

过滤器 注解

字段: 已输入 21 个, 已过滤 6 个, 已重命名 0 个, 已输出 15 个

字段	过滤器	字段
客户号	✗	客户号
客户姓名	✗	客户姓名
证件号码	✗	证件号码
年龄	→	年龄
性别	→	性别
婚姻状态	→	婚姻状态
教育程度	→	教育程度
职业类别	→	职业类别
户籍	→	户籍
居住类型	→	居住类型


☒ 查看当前字段
 ☐ 查看未使用的字段设置

确定 取消 应用(A) 重置(R)

➤ “类型”节点属性设置




- 接着使用 C5.0 决策树算法来简单分析用户的人口属性对信用等级的影响：由下图可知，对于信用等级的重要性程度依次为车辆情况、年龄、个人收入、居住类型、教育程度和工作年限等，其中具有较大影响的是车辆情况、年龄和个人收入，主要体现的还是客户的一个整体的财富情况；但是保险缴纳却成为了最不重要的一项，一般来说，保险缴纳情况良好的客户，其资金情况应该较为充沛，从而还款应当较为及时有着较好的信用情况，但是此处却显示其并没有我们预想的那么重要。



1.2 信用卡申请成功影响因素

- 整体数据流：使用线性支持向量机 SVM 以及逻辑回归分析影响信用卡申请成功的因素



- 信用等级根据是否申请成功进行重新分类，户籍根据地理区域进行进一步分类

设置 注解

模式: ☒ 单个 ☐ 多个
重新分类为: ☒ 新字段 ☐ 现有字段

重新分类字段:
信用等级

新字段名:
是否申请成功

重新分类值:

原始值	新值
A-优质客户	成功
B-良好客户	成功
C-普通客户	成功
D-风险客户	成功
F-未通过用户	失败

用于未指定的值: ☒ 原始值 ☐ 缺省值

确定 取消 应用(A) 重置(R)

设置 注解

模式: ☒ 单个 ☐ 多个
重新分类为: ☒ 新字段 ☐ 现有字段

重新分类字段:
户籍

新字段名:
地理区域

重新分类值:

原始值	新值
上海	华东
内蒙古	华北
北京	华北
吉林	东北
四川	西南

用于未指定的值: ☒ 原始值 ☐ 缺省值

确定 取消 应用(A) 重置(R)

- 使用分区节点将数据按照 70%训练集和 30%测试集的比例分配记录

分区

生成(G) 预览(P)

设置 注解

分区字段: 分区

分区: ☒ 训练和测试(T) ☐ 训练、测试和验证(V)

训练分区大小: 70 标签: 培训 值 = "1_培训"

测试分区大小: 30 标签: 测试 值 = "2_测试"

验证分区大小: 0 标签: 验证 值 = "3_验证"

大小总计: 100%

值: ☒ 使用系统定义值 ("1"、"2" 和 "3")
☒ 将标签追加为系统定义的值
☐ 将标签用作值

☒ 可重复的分区分配

种子: 1234567 生成

☐ 使用唯一字段来分配分区:

确定 取消 应用(A) 重置(R)

- 使用线性 SVM 模型进行分析并计算各变量的预测变量重要性，并将结果生成表格。

由表得到“\$LC-是否申请成功”列显示预测成功概率

表格 (18 个字段, 10,000 条记录)																		
文件(E)		编辑(E)		生成(G)														
表格		注解																
年龄	性别	婚姻状态	教育程度	职业类别	户籍	居住类型	车辆情况	保险缴纳	工作年限	个人...	信贷情况	信用等级	是否申请成功	地理区域	分区	SL-是否申请成功	SLC-是否申请成功	
1	45...	女	未婚	本科	私营企...	海南	租房	无	有	22.000	10000	没有贷款记录	F-未通过用户	失败	华南	1_培训	失败	0.690
2	21...	男	未婚	大专	外资企...	四川	租房	无	无	1.000	10000	没有贷款记录	F-未通过用户	失败	西南	1_培训	失败	0.936
3	22...	女	未婚	大专	私营企...	天津	租房	无	无	2.000	10000	没有贷款记录	F-未通过用户	失败	华北	1_培训	失败	0.939
4	25...	男	未婚	本科	个体户	上海	租房	有	有	2.000	5.7E9	现在没有贷款	B-良好客户	成功	华东	2_测试	成功	0.805
5	25...	男	未婚	本科	私营企...	西藏	自购房	有	有	2.000	6.8E9	正常还款	A-优质客...	成功	西南	1_培训	成功	0.848
6	25...	女	未婚	本科	私营企...	江西	租房	有	有	2.000	9.9E10	正在偿还	B-良好客...	成功	华东	1_培训	成功	0.861
7	32...	男	未婚	本科	私营企...	陕西	租房	有	无	9.000	9.9E10	现在没有贷款	B-良好客...	成功	西北	1_培训	成功	0.719
8	52...	女	未婚	本科	私营企...	河北	租房	无	有	29.000	9.9E10	正常还款	B-良好客...	成功	华北	1_培训	成功	0.842
9	32...	男	未婚	大专	私营企...	湖北	租房	无	有	12.000	10000	没有贷款记录	F-未通过用户	失败	华中	1_培训	失败	0.903
10	41...	女	已婚	本科	个体户	重庆	租房	无	有	18.000	10000	没有贷款记录	F-未通过用户	失败	西南	1_培训	失败	0.699
11	56...	男	未婚	大专	私营企...	重庆	其他	无	无	36.000	10000	没有贷款记录	F-未通过用户	失败	西南	1_培训	失败	0.845
12	33...	男	未婚	高中	个体户	重庆	租房	无	无	15.000	10000	没有贷款记录	F-未通过用户	失败	西南	1_培训	失败	0.911
13	34...	男	未婚	本科	国有企业	四川	租房	无	有	11.000	10000	没有贷款记录	F-未通过用户	失败	西南	2_测试	失败	0.757
14	35...	男	已婚	本科	私营企...	广西	其他	无	有	12.000	10000	没有贷款记录	F-未通过用户	失败	华南	1_培训	失败	0.767
15	36...	男	未婚	初中及...	私营企...	上海	其他	无	无	22.000	10000	没有贷款记录	F-未通过用户	失败	华东	2_测试	失败	0.927
16	31...	女	已婚	高中	外资企...	宁夏	租房	无	无	13.000	10000	还在拖欠	F-未通过用户	失败	西北	2_测试	失败	0.997
17	42...	女	已婚	初中及...	私营企...	海南	其他	无	无	14.000	10000	还在拖欠	F-未通过用户	失败	华南	1_培训	失败	0.998
18	29...	男	未婚	高中	外资企...	江西	租房	无	无	11.000	10000	没有贷款记录	F-未通过用户	失败	华东	1_培训	失败	0.928
19	23...	男	未婚	高中	私营企...	甘肃	租房	无	无	5.000	10000	没有贷款记录	F-未通过用户	失败	西北	1_培训	失败	0.935
20	28...	男	已婚	大专	国有企业	安徽	租房	无	无	8.000	10000	没有贷款记录	F-未通过用户	失败	华东	1_培训	失败	0.914
21	55...	女	已婚	本科	私营企...	贵州	租房	无	有	32.000	10192	没有贷款记录	F-未通过用户	失败	西南	1_培训	失败	0.707
22	24...	男	未婚	本科	个体户	湖南	租房	无	有	1.000	10192	没有贷款记录	F-未通过用户	失败	华中	2_测试	失败	0.860
23	23...	男	未婚	本科	私营企...	宁夏	自购房	有	有	0.000	10192	现在没有贷款	F-未通过用户	失败	西北	1_培训	失败	0.665
24	24...	男	未婚	本科	国有企业	江西	租房	无	有	1.000	10192	现在没有贷款	F-未通过用户	失败	华东	1_培训	失败	0.874
25	28...	男	未婚	本科	私营企...	新疆	租房	无	有	5.000	10192	现在没有贷款	F-未通过用户	失败	西北	1_培训	失败	0.827
26	24...	女	未婚	初中及...	私营企...	辽宁	租房	无	无	13.000	10280	逾期还款	F-未通过用户	失败	东北	1_培训	失败	0.976
27	26...	男	未婚	初中及...	其他企...	辽宁	其他	无	无	9.000	10280	逾期还款	F-未通过用户	失败	东北	2_测试	失败	0.982
28	27...	男	未婚	高中	私营企...	上海	租房	无	无	9.000	10280	逾期还款	F-未通过用户	失败	华东	2_测试	失败	0.974
29	38...	男	未婚	高中	私营企...	上海	租房	无	无	20.000	10280	还在拖欠	F-未通过用户	失败	华东	1_培训	失败	0.984
30	45...	男	未婚	大专	外资企...	广东	租房	无	无	25.000	10280	还在拖欠	F-未通过用户	失败	华南	1_培训	失败	0.975
31	28...	男	未婚	大专	私营企...	湖南	租房	无	无	8.000	10294	逾期还款	F-未通过用户	失败	华中	1_培训	失败	0.995
32	35...	男	未婚	硕士及...	私营企...	宁夏	租房	无	有	10.000	10294	逾期还款	F-未通过用户	失败	西北	1_培训	失败	0.949
33	28...	男	未婚	硕士及...	私营企...	山西	租房	无	有	3.000	10294	现在没有贷款	F-未通过用户	失败	华北	1_培训	失败	0.668

- 模型评析结果分析,训练过程中准确率为 99.31%,应用测试集进行验证,线性 SVM 分类准确性为 94.88%。
- 在申请成功记录中,分类正确的记录数为 4138,达 99%,失败记录数为 28,占 1%


模型信息

目标字段	是否申请成功
模型构建方法	线性 SVM
输入的预测变量数	12
最终模型中的预测变量数	12
规则化类型	L2
惩罚参数 (Lambda)	0.100
分类准确性	99.3%

混淆矩阵

实测	预测		
	成功	失败	比例正确
成功	4,138	28	0.99
失败	20	2,784	0.99
比例正确	1.00	0.99	0.99

预测变量重要性




输出字段 是否申请成功的结果


比较 \$L-是否申请成功 与 是否申请成功

“分区”	1_培训	2_测试
正确	6,922	99.31%
错误	48	0.69%
总计	6,970	3,030

- 年收入重要性最高，其次是保险缴纳、车辆情况、信贷情况，婚姻变量作用不显著
- 使用逻辑回归对各影响因素进行分析



- 各影响因素变量的分布情况，包括各个分类输入变量的数量及所占总记录数的比例



- 模型拟合状况，显著性为 0 表示拟合效果较好

Model Fitting Information				
Model	Model Fitting Criteria	Likelihood Ratio Tests		
	-2 Log Likelihood	Chi-Square	df	Sig.
Intercept Only	13496.656			
Final	83.330	13413.325	1155	.000

- 因变量虚拟回归系数，各参数说明逻辑回归模型质量较好

Pseudo R-Square

Cox and Snell	.739
Nagelkerke	.997
McFadden	.994


- 使用分析节点对结果进行分析，其中训练集准确率为 99.97%，测试集准确率为 100%，说明逻辑回归具有较高的应用价值

输出字段 是否申请成功 的结果

比较 \$L-是否申请成功 与 是否申请成功


“分区”	1_培训		2_测试	
正确	6,968	99.97%	3,030	100%
错误	2	0.03%	0	0%
总计	6,970		3,030	

- 将逻辑回归结果以回归方程形式进行量化，用户申请信用卡时将其提交的资料应用于回归方程，即可得到审批结果



2. 信用卡客户信用等级影响因素

- 数据预处理后，以信用等级为目标运行 C5.0 决策树算法，得到模型的变量重要性分布情况。由图可知，银行在评判个人用户信息等级时，最重要的评价因素是用户的年收入，次重要是居住类型。




- 展开 C5.0 决策树进行分析：年收入越高的用户信用等级越高；当年收入不变时，用户居住类型为自购房，或是有车辆，缴纳了保险，信用等级就越高。

```

[ 年收入 <= 499,200 [ 模式：D-风险客户 ]
[ 车辆情况 = 有 [ 模式：D-风险客户 ]
[ 年收入 <= 80,000 [ 模式：D-风险客户 ]
[ 年龄 <= 35 [ 模式：D-风险客户 ]
[ 教育 in [ "初中及以下", "本科", "高中" ] [ 模式：D-风险客户 ] => D-风险客户
[ 教育 in [ "大专" ] [ 模式：D-风险客户 ]
[ 教育 in [ "硕士及以上" ] [ 模式：D-风险客户 ]
[ 年龄 > 35 [ 模式：C-普通客户 ]
[ 单笔消费最低 <= 13,400 [ 模式：D-风险客户 ] => D-风险客户
[ 单笔消费最低 > 13,400 [ 模式：C-普通客户 ]
[ 年收入 > 80,000 [ 模式：B-良好客户 ]
[ 年龄 <= 28 [ 模式：C-普通客户 ]
[ 保险缴纳 = 有 [ 模式：C-普通客户 ]
[ 保险缴纳 = 无 [ 模式：D-风险客户 ]
[ 年龄 > 28 [ 模式：B-良好客户 ]
[ 保险缴纳 = 有 [ 模式：B-良好客户 ]
[ 保险缴纳 = 无 [ 模式：C-普通客户 ] => C-普通客户
[ 车辆情况 = 无 [ 模式：D-风险客户 ]
[ 年收入 <= 80,000 [ 模式：D-风险客户 ] => D-风险客户
[ 年收入 > 80,000 [ 模式：D-风险客户 ]
[ 保险缴纳 = 有 [ 模式：C-普通客户 ]
[ 年龄 <= 26 [ 模式：D-风险客户 ]
[ 年龄 > 26 [ 模式：C-普通客户 ]
[ 保险缴纳 = 无 [ 模式：D-风险客户 ]
[ 年龄 <= 40 [ 模式：D-风险客户 ]
[ 年龄 > 40 [ 模式：C-普通客户 ]
[ 年收入 > 499,200 [ 模式：B-良好客户 ]
[ 居住类型 = 其他 [ 模式：B-良好客户 ]
[ 保险缴纳 = 有 [ 模式：B-良好客户 ] => B-良好客户
[ 保险缴纳 = 无 [ 模式：C-普通客户 ] => C-普通客户
[ 居住类型 = 租房 [ 模式：B-良好客户 ]
[ 保险缴纳 = 有 [ 模式：B-良好客户 ]
[ 教育 in [ "初中及以下", "大专", "高中" ] [ 模式：B-良好客户 ] => B-良好客户
[ 教育 in [ "本科" ] [ 模式：B-良好客户 ]
[ 教育 in [ "硕士及以上" ] [ 模式：B-良好客户 ]
[ 保险缴纳 = 无 [ 模式：C-普通客户 ]
[ 年龄 <= 35 [ 模式：C-普通客户 ]
[ 年龄 > 35 [ 模式：B-良好客户 ]
[ 居住类型 = 自购房 [ 模式：A-优质客户 ]
[ 日均次数 <= 9 [ 模式：A-优质客户 ]
[ 年龄 <= 21 [ 模式：B-良好客户 ]
[ 年龄 > 21 [ 模式：A-优质客户 ] => A-优质客户
[ 日均次数 > 9 [ 模式：A-优质客户 ]
[ 年龄 <= 29 [ 模式：B-良好客户 ] => B-良好客户
[ 年龄 > 29 [ 模式：A-优质客户 ] => A-优质客户

```

- 完整数据流



3. 基于消费的信用等级影响因素

- 对信用卡用户的消费行为进行统计分析，探究消费行为和信用等级之间的关系

➤ 合并“消费历史记录”和“客户信用记录”两表

变量添加自 数据集3

合并方法 变量

☐ 基于文件顺序的一对一合并(O)

☒ 基于键值的一对一合并(N)

☐ 基于键值的一对多合并(M)

选择查找表

☐ 数据集2*

☒ 数据集3

*活动的数据集

对于基于键值的合并，必须按键值的顺序对文件进行排序。

☒ 在合并前按键值对文件进行排序(S)

键变量(K):

客户号

卡号

卡类别

使用“变量”选项卡来添加或删除键变量

确定 粘贴(P) 重置(R) 取消 帮助

*无标题3 [数据集2] - IBM SPSS Statistics 数据编辑器

文件(E) 编辑(E) 查看(V) 数据(D) 转换(T) 分析(A) 图形(S) 实用程序(U) 扩展(X) 窗口(W) 帮助(H)


可视: 12/12 个变量

	客户号	信用总评分	信用等级	审批结果	卡号	卡类别	币种 代码	日均消费金额	日均次数	单笔消费最小金额	单笔
1	0000999963835873		86 B-良好客户	0-通过	3276142808017253	金卡	CNY	30	3	1.5	
2	0000999973835875		90 A-优质客户	0-通过	3276142808017285	白金卡	CNY	30	1	1.5	
3	0000999983959391		86 B-良好客户	0-通过	3276142808017290	金卡	CNY	31	5	1.5	
4	0000999983959392		84 B-良好客户	0-通过	3276142808017319	金卡	CNY	31	7	1.5	
5	0000999983959393		87 B-良好客户	0-通过	3276142808017326	金卡	CNY	31	2	1.5	
6	0000999993800668		61 D-风险客户	0-通过	3276270201901409	普卡	CNY	39	2	3.0	
7	0000999993801038		60 D-风险客户	0-通过	3276270801006892	普卡	CNY	42	2	3.0	
8	0000999993801345		60 D-风险客户	0-通过	3276270801007448	普卡	CNY	46	2	3.0	
9	0000999993801550		60 D-风险客户	0-通过	3276270801007683	普卡	CNY	48	7	3.3	
10	0000999993802043		60 D-风险客户	0-通过	3276270801008910	普卡	CNY	53	2	3.9	
11	0000999993802214		60 D-风险客户	0-通过	3276270801009208	普卡	CNY	55	6	4.0	
12	0000999993802600		60 D-风险客户	0-通过	3276270808005495	普卡	CNY	57	5	4.4	
13	0000999993802702		60 D-风险客户	0-通过	3276270808006608	普卡	CNY	58	3	4.5	
14	0000999993802780		60 D-风险客户	0-通过	3276270808006950	普卡	CNY	58	2	4.7	
15	0000999993802815		61 D-风险客户	0-通过	3276270808007665	普卡	CNY	59	5	4.7	
16	0000999993802848		60 D-风险客户	0-通过	3276270808007706	普卡	CNY	59	1	4.7	
17	0000999993802984		60 D-风险客户	0-通过	3276270808013740	普卡	CNY	60	2	4.9	
18	0000999993802995		60 D-风险客户	0-通过	3276270808013914	普卡	CNY	60	2	5.0	
19	0000999993803568		60 D-风险客户	0-通过	3276270808016055	普卡	CNY	66	5	5.0	


数据视图 变量视图

IBM SPSS Statistics 处理程序就绪 Unicode: 开


- 制作箱图分析日均消费金额与信用等级的关系。由图可知，优质客户的日均消费金额比较高，风险客户日均消费金额较低，说明用户消费能力越强，其信用卡的等级越高。



- 制作箱图分析单笔消费最大金额与信用等级的关系。由图可知，随着客户信用等级的降低，单笔消费最大金额也逐渐减少。




- 使用 C5.0 算法分析信用等级与消费行为之间的关系。分析可知，单笔消费最大金额具有较大的重要性。



4. 信用卡欺诈判断模型

4.1 Apriori 算法的欺诈模型

- 我们先研究基于 Apriori 算法的欺诈模型；我们先调用“消费历史记录表”中的数据，因为决策树不适合分析连续变量，所以我们需要根据已有的数据来创造几个可以用于 Apriori 决策树分析的数据变量。整体流程如下：



- 首先，创造“单笔是否透支”变量，根据“单笔最大消费金额”减去“额度”是否大于零，来说明客户是否存在透支现象。

模式: ☒ 单个 ☐ 多个

导出字段:
单笔是否透支

导出为: 条件

字段类型: 分类

如果:
1 (单笔消费最大金额 - 额度) > 0

则:
1 '超过'

否则:
1 '未超过'

确定 取消 应用(A) 重置(R)

- 其次，导出“单笔是否透支”变量，根据用户的日均收入和年度消费金额可以得到客户日均消费金额是否超过了收入。

模式: ☒ 单个 ☐ 多个

导出字段:
日均消费是否超过收入

导出为: 条件

字段类型: 分类

如果:
1 (日均消费金额 - 个人收入_连续 / 365) > 0

则:
1 '超过'

否则:
1 '未超过'

确定 取消 应用(A) 重置(R)

- 第三，导出“刷卡频率”变量，我们将离散化的刷卡日均次数变成分类或者标称变量，将小于 5 次的定义为不频繁，5 次到 10 次的定义为频繁，超过 10 次的定义为非常频繁。使用 if 语句简单定义。

模式: ☒ 单个 ☐ 多个

导出字段:
刷卡频率

导出为: 公式

字段类型: <缺省>

公式:

```

1 if (日均次数 <= 5) then '不频繁'
2 else if (日均次数 <= 10) then '频繁'
3 else '非常频繁'
4 endif
5 endif

```

确定 取消 应用(A) 重置(R)


- 接下来，用过滤器将无关的变量以及重复的变量过滤掉，使得数据更加清晰整洁，例如对于“客户号”、“卡号”等表面用户个人的变量消除，以及由于“额度”和“卡类别”其实所代表信息相同且额度更加方便分析，因此去除“卡类别”，再者，删去类似“币种代码”、“单笔消费最小金额”等无效变量。



- 使用类型节点，将我们之前导出的“单笔是否透支”“日均消费是否超过收入”“刷卡频率”三个变量设为“输入”，“是否存在欺诈”设为“目标”，其他无关变量设为“无”。



- 接着调用“Apriori”模型来进行分析，但是根据默认运行时，会发现软件提示你的阈值过高难以运行分析数据，这是因为欺诈发生的概率太低，在所有的客户记录中只占 4.5%，所以，根据调试，我们可以把支持度设置为 0，置信度设置为 60 即可，因为我们所关注的重点在于他们的关联性和相关的紧密程度。




- 运行后，由图可知，刷卡频率非常频繁即单日刷卡次数超过 10 次与欺诈行为紧密联系，置信度达到了惊人的 100%，所以我们可以认为当客户日均刷卡次数超过 10 次时基本可以断定其出现了欺诈行为，需要特别关注。其次，可以看到，当同时出现刷卡次数频繁即日均刷卡次数大于 5 次且存在日均消费超过收入以及出现透支时，我们也可以基本断定客户出现了欺诈行为，因为图中置信度高达 99.39%。
- 当然，图中分析结果的唯一缺点就是其支持度过低，这我们也可以理解，因为数据中的欺诈比例低达 4.5%，所以我们可以更改和筛选原数据，使得欺诈的比例增加，从而可以有效提高置信度，但是从根本意义上来说，这是没有多大用处的，我们还是要增加欺诈案例的绝对数量而不是相对数量。

后项	前项	支持度百分比	置信度百分比
是否存在欺诈	刷卡频率 = 非常频繁	0.286	100.0
是否存在欺诈	刷卡频率 = 非常频繁 日均消费是否超过收入	0.151	100.0
是否存在欺诈	刷卡频率 = 频繁 单笔是否透支 日均消费是否超过收入	2.771	99.394
是否存在欺诈	刷卡频率 = 频繁 单笔是否透支	3.829	73.246
是否存在欺诈	刷卡频率 = 非常频繁	0.621	70.27
是否存在欺诈	刷卡频率 = 非常频繁 单笔是否透支	0.453	62.963

4.2 基于 discriminant analysis 的欺诈模型

- 在使用了 Apriori 决策树后，我们不妨在看看使用 discriminant analysis model 的分析效果。整体流程如下：



- 首先，我们要进行分区，30%作为测试集，70%作为训练集。



- 由于在原数据中，是否发生欺诈的表示为“1”或“0”，被作为数值类型，所以，我们需要调用“类型”将其改成标称类的属性，即“标记”类型，从而方便后续的建模分析。




- 调用“判断”模型，进行手动设置，目标选择为“是否存在欺诈”（如果之前不将次变量设为‘标记’类型的话，这里就无法选择），输入端，我们选择“日均消费金额”、“日均次数”、“单笔消费最小金额”和“单笔消费最大金额”来作为自变量，最后分区选择之前设置的分区变量。

并且，为了更好理解分析结果，在“专家”栏中选择专家模式，点击下方的“输出”，以此选择“Box’s M”、“组内相关”和“Fisher’s”。



- 运行后，我们可以获得如下图的分析结果：首先可以看到，“日均次数”对于“是否存在欺诈”的影响程度显著大于其他三项，说明当客户的日均信用卡使用次数过多时，我们需要注意其极有可能出现欺诈行为。



- 其次，如下图所示，可以看到自由度 df 为 2，卡方值 chi-square 为 791，Sig 小数点后 3 个 0，说明结果非常显著！

Eigenvalues				
Function	Eigenvalue	% of Variance	Cumulative %	Canonical Correlation
1	.211 ^a	100.0	100.0	.417

a. First 1 canonical discriminant functions were used in the analysis.

Wilks' Lambda				
Test of Function(s)	Wilks' Lambda	Chi-square	df	Sig.
1	.826	791.151	4	.000

- 再者，我还可以看到，在第一幅图：标准化的判别系数表中，以此体现的是当其他变量固定时，其自身与目标变量的相关程度，体现的是其对于目标变量的重要程度，那么我们可以看到“日均次数”的重要程度远远高过其他变量，这与之前的那副图是一致的。

而右边的结构矩阵表示的是变量与目标之间的简单相关程度，与左边的标准化系数相比，可以看到两者结果大体相同。

Standardized Canonical
Discriminant Function
Coefficients

	Function
	1
日均消费金额	.146
日均次数	1.008
单笔消费最小金额	-.078
单笔消费最大金额	-.177

Structure Matrix

	Function
	1
日均次数	.990
单笔消费最大金额	-.016
单笔消费最小金额	-.013
日均消费金额	-.011

- 然后，根据下图分类函数系数表可知，其体现的结果也于上述表格的描述一致，同时我们也能发现，对于不发生欺诈，其他三个变量作用也微乎其微，日均次数的重要性略微变低，这也说明：你次数太多很有可能欺诈，但是次数较少，我们不能说你很大程度不欺诈。


Classification Function Coefficients

	是否存在欺诈	
	1.0	0.0
日均消费金额	5.551E-6	-1.098E-5
日均次数	1.830	.709
单笔消费最小金额	.000	.000
单笔消费最大金额	-3.601E-6	2.755E-6
(Constant)	-7.251	-1.824


Fisher's linear discriminant functions

4.3 基于分类算法的欺诈模型

- 我们还可以看看基于分类算法的结果，具体流程如下：



- 考虑基于线性 SVM 的欺诈模型，使用“样本”记录选项使得未欺诈的数据量变成原来的 20%，提高了欺诈的比例，为了方便 LSVM 的分析。



- 使用分区，依旧时 30%测试，70%训练。注意使用“区分”将“日均使用次数”、“日均消费金额”、“单笔最高”和“单笔最低”的相同记录过滤掉。



- 通过“类型”设置目标变量和输入变量后，调用 LSVM 模型得到结果：下图为预览中的情况，成功的概率还是很高的，大多在 60%到 70%左右。

从 是否存在欺诈 节点预览 (15 个字段, 10 条记录)								
文件(E) 编辑(E) 生成(G) 打印(P) 刷新(F5) 帮助(H)								
表格 注解								
	消费最大金额	个人收入_连续	是否存在欺诈	样本权重	分区	SL-是否存在欺诈	SLC-是否存在欺诈	
1	30.300	68000000000...	0.000		5.001 1_培训	0.000	0.753	
2	30.400	99000000000...	0.000		5.001 1_培训	0.000	0.579	
3	50.200	11230.000	0.000		5.001 1_培训	0.000	0.714	
4	55.700	12375.000	0.000		5.001 1_培训	0.000	0.672	
5	58.200	12750.000	0.000		5.001 1_培训	0.000	0.715	
6	65.500	13280.000	0.000		5.001 1_培训	0.000	0.753	
7	63.700	13013.000	0.000		5.001 1_培训	0.000	0.672	
8	67.800	13380.000	0.000		5.001 1_培训	0.000	0.672	
9	76.900	13984.000	0.000		5.001 1_培训	0.000	0.753	
10	76.600	13984.000	0.000		5.001 2_测试	0.000	0.714	

- 由图可知，分类的准确性为 85.8%，实际欺诈且预测为欺诈的准确率为 49%，实际未欺诈且预测未欺诈的准确率为 95%。


模型信息

目标字段	是否存在欺诈
模型构建方法	线性 SVM
输入的预测变量数	4
最终模型中的预测变量数	4
规则化类型	L2
惩罚参数 (Lambda)	0.100
分类准确性	85.8%


混淆矩阵

		预测		
		1.0	0.0	比例正确
实测	1.0	95	97	0.49
	0.0	42	743	0.95
比例正确		0.69	0.88	0.86

- 由下图可知，“日均次数”最为重要，也就是说如果客户日均次数过高，有极大可能发生欺诈。



➤ 使用cart模型的欺诈模型分析，主要流程如下：




➤ CART分析结果：图中成功概率普遍较高。

从 是否存在欺诈 节点预览 (15 个字段, 10 条记录) #1

	消费最大金额	个人收入_连续	是否存在欺诈	样本权重	分区	\$R-是否存在欺诈	\$RC-是否存在欺诈
1	30.300	57000000000....	0.000		5.001 2_测试	0.000	0.956
2	31.000	99000000000...	0.000		5.001 1_培训	0.000	0.956
3	30.400	99000000000...	0.000		5.001 1_培训	0.000	0.956
4	45.500	10860.000	0.000		5.001 2_测试	0.000	0.692
5	56.000	12460.000	0.000		5.001 1_培训	0.000	0.956
6	69.900	13720.000	0.000		5.001 2_测试	0.000	0.956
7	11000.000	17000.000	1.000		1.000 2_测试	0.000	0.956
8	10003.000	18617.000	1.000		1.000 2_测试	0.000	0.956
9	100.000	18750.000	0.000		5.001 2_测试	0.000	0.956
10	100.000	17000.000	1.000		1.000 1_培训	0.000	0.692

确定

- CART分析的决策树如下：可以看到，首先根据日均消费次数是否超过5.5次划分，改进的增益有0.169；接着根据单笔消费金额是否超过9646元划分，改进的增益只有0.009。



- 使用分析，查看分析结果：可以看到预测的准确率高达88.99%，再根据下面的符合矩阵，可以计算得到True Active=58/(58+29)=66.7%,具有较强的实际指导价值。而且最后一栏的给分系数分别为0.7和0.8左右，信息增益效果显著。

输出字段 是否存在欺诈的结果

单独模型

比较 \$L-是否存在欺诈 与 是否存在欺诈

分区	1_培训	2_测试
正确	839 85.96%	380 88.99%
错误	137 14.04%	47 11.01%
总计	976	427

\$L-是否存在欺诈 的符合矩阵 (行表示实际值)

分区=1_培训	0.000000	1.000000
0.000000	751	45
1.000000	92	88
分区=2_测试	0.000000	1.000000
0.000000	322	18
1.000000	29	58

绩效评估

分区=1_培训	
0.000000	0.088
1.000000	1.277
分区=2_测试	
0.000000	0.142
1.000000	1.321

\$L-是否存在欺诈 的置信度值报告

分区=1_培训	
范围	0.505 - 0.971
平均正确性	0.682
平均不正确性	0.594
正确性始终高于	0.962 (观测值的 0.1%)
不正确性始终低于	0.507 (观测值的 0.2%)
90.01% 以上的准确性	0.531
2.0 以上的折衷正确性	0.569 (观测值的 93.07%)
分区=2_测试	
范围	0.507 - 0.976
平均正确性	0.68
平均不正确性	0.601
正确性始终高于	0.972 (观测值的 0.23%)
不正确性始终低于	0.507 (观测值的 0%)
90.07% 以上的准确性	0.521
2.0 以上的折衷正确性	0.569 (观测值的 94.71%)


评估度量

分区	1_培训	2_测试
模型	AUC	Gini
\$L-是否存在欺诈	0.857	0.714
	AUC	Gini
	0.905	0.809


5. 欺诈人口属性分析

5.1 欺诈人口属性统计分析


- 首先使用 spss statistics 对发生欺诈的数据进行人口属性的统计分析，如：性别、年龄、婚姻、教育程度等等。
- 发生欺诈的人中，男性显著大于女性。




- 年龄分布中，可以看到发生欺诈行为的年龄主要集中在26~33岁：这可能是青年由于成家立业以及消费观念，所需要的资金使用量较高，消费欲望较大，从而导致信用卡消费过多出现欺诈行为；以及特别明显的20岁：这可能是由于高中生刚刚步入大学，消费欲望迅速得到释放导致这个年龄段群体的信用卡使用极为频繁，以及没有个人收入，从而易发生欺诈。




- 发生欺诈的婚姻情况可以发现，未婚者占比较大，而离异后反而更不容易发生违约欺诈行为。





- 接着，根据省市情况，可以看到广东、河北以及上海的欺诈占比明显较高。




➤ 再例如，对于企业类型，可以发现私营企业占欺诈占比非常高




➤ 以及各类属性占比情况，此处不再一一赘述，可以观察下图即可知道相应情况：





5.2 基于 logistics 的欺诈人口属性分析

- 此外，我们使用逻辑回归的模型对欺诈情况进行分析：先将客户信用和消费信息两个信息表进行合并，过滤掉不属于人口属性的变量，用“类型”将是否欺诈作为目标变量，使用 logistics 进行分析，具体流程如下：



- 如图所示，卡方为236，自由度为48，且Sig低于0.001，结果非常显著

Model Fitting Information

Model	Model Fitting Criteria	Likelihood Ratio Tests		
	-2 Log Likelihood	Chi-Square	df	Sig.
Intercept Only	2185.797			
Final	1949.309	236.489	48	.000

- 由参数估计图如下，

Parameter Estimates

是否存在欺诈 ^a	B	Std. Error	Wald	df	Sig.	Exp(B)	95% Confidence Interval for Exp(B)	
							Lower Bound	Upper Bound
0	Intercept	5.157	.865	35.573	1	.000		
	个人收入_连续	.000	.000	12.199	1	.000	1.000	1.000
	年龄_连续	.031	.013	5.392	1	.020	1.031	1.058
	工作年限	-.013	.013	1.001	1	.317	.987	1.012
	[性别=男]	-.004	.145	.001	1	.980	.996	1.323
	[性别=女] 0 ^b	.	.	.	0	.	.	.
	[婚姻状态=离异]	-.352	.303	1.350	1	.245	.703	1.274
	[婚姻状态=丧偶]	17.264	.000	.	1	.	31466070.38	31466070.38
	[婚姻状态=未婚]	-.201	.152	1.750	1	.186	.818	1.102
	[婚姻状态=已婚] 0 ^b	.	.	.	0	.	.	.
	[户籍=安徽]	-1.192	.539	4.879	1	.027	.304	.874
	[户籍=北京]	-.250	.585	.182	1	.670	.779	2.453
	[户籍=福建]	-.475	.608	.610	1	.435	.622	2.048
	[户籍=甘肃]	-.669	.603	1.229	1	.268	.512	1.671
	[户籍=广东]	-.951	.506	3.537	1	.060	.386	1.041
	[户籍=广西]	.164	.691	.057	1	.812	1.179	4.569
	[户籍=贵州]	-.488	.626	.608	1	.435	.614	2.093
	[户籍=海南]	-.486	.604	.647	1	.421	.615	2.009
	[户籍=河北]	-1.595	.512	9.694	1	.002	.203	.554
	[户籍=河南]	-.493	.603	.669	1	.413	.611	1.991
	[户籍=黑龙江]	-.646	.588	1.204	1	.273	.524	1.662
	[户籍=湖北]	-1.216	.540	5.076	1	.024	.296	.854
	[户籍=湖南]	-1.237	.540	5.246	1	.022	.290	.837
	[户籍=吉林]	.107	.686	.024	1	.876	1.113	4.270
	[户籍=江苏]	-.831	.588	1.999	1	.157	.436	1.379
	[户籍=江西]	.189	.685	.076	1	.783	1.208	4.623
	[户籍=辽宁]	.473	.745	.403	1	.526	1.604	6.908
	[户籍=内蒙古]	.229	.689	.110	1	.740	1.257	4.851
	[户籍=宁夏]	-1.262	.546	5.350	1	.021	.283	.825
	[户籍=青海]	-.940	.558	2.845	1	.092	.390	1.165
	[户籍=山东]	-.912	.561	2.641	1	.104	.402	1.207
	[户籍=山西]	-.107	.648	.027	1	.868	.898	3.199
	[户籍=陕西]	-.801	.576	1.932	1	.165	.449	1.389
	[户籍=上海]	-.638	.520	1.509	1	.219	.528	1.463
	[户籍=四川]	-.701	.575	1.488	1	.223	.496	1.530
	[户籍=天津]	-.709	.575	1.519	1	.218	.492	1.520
	[户籍=西藏]	-.842	.869	.939	1	.332	.431	2.365
	[户籍=新疆]	-.185	1.119	.027	1	.869	.831	7.451
	[户籍=浙江]	-.617	.587	1.105	1	.293	.540	1.705
	[户籍=重庆] 0 ^b	.	.	.	0	.	.	.
	[教育程度=本科]	-1.140	.347	10.823	1	.001	.320	.631
	[教育程度=初中及以下]	-.787	.447	3.100	1	.078	.455	1.093
	[教育程度=大专]	-.334	.379	.778	1	.378	.716	1.504
	[教育程度=高中]	-1.386	.390	12.657	1	.000	.250	.537
	[教育程度=硕士及以上] 0 ^b	.	.	.	0	.	.	.
	[居住类型=其他]	-1.567	.349	20.192	1	.000	.209	.413
	[居住类型=自购房]	-.405	.549	.545	1	.460	.667	1.955
	[居住类型=租房] 0 ^b	.	.	.	0	.	.	.

[职业类别=个体户]	-.011	.249	.002	1	.966	.989	.608	1.611
[职业类别=国有企业]	.566	.386	2.152	1	.142	1.762	.827	3.754
[职业类别=其他企业]	-.250	.320	.612	1	.434	.779	.416	1.457
[职业类别=私营企业]	.012	.192	.004	1	.952	1.012	.695	1.473
[职业类别=外资企业]	0 ^b	.	.	0	.	.	.	.
[保险缴纳=无]	-.936	.205	20.807	1	.000	.392	.262	.586
[保险缴纳=有]	0 ^b	.	.	0	.	.	.	.
[车辆情况=无]	-1.035	.517	4.009	1	.045	.355	.129	.978
[车辆情况=有]	0 ^b	.	.	0	.	.	.	.

a. The reference category is: 1.


b. This parameter is set to zero because it is redundant.

- 由上图可知：与欺诈相关的年龄、收入、户籍、婚姻等情况的分析与上节的统计分析图表所示的重要特征相同。

由此，我们根据logistics和统计分析两个结果可以得出一个描述：一个高中或本科学历的未婚人士，没有固定住所，且没有私人车辆以及保险缴纳，从事国有或其他类型企业的工作，那么他欺诈概率极大。

5.3 基于决策树分析逾期还款的客户特征

- 关于逾期还款的客户特征分析，具体流程如下：



- 将拖欠历史记录中的数据拖欠金额和拖欠时间进行打分，变成离散值变量。

拖欠金额得分

导出为: 公式

字段类型: <缺省>

公式:


```

1 if (拖欠总金额 <= 2500) then 20
2 else if (拖欠总金额 <= 5000) then 60
3 else if (拖欠总金额 <= 22000) then 75
4 else 100
5 endif
6 endif
7 endif
          
```

拖欠时间得分

导出为: 公式

字段类型: <缺省>

公式:


```

1 if (逾期天数 <= 30) then 20
2 else if (逾期天数 <= 60) then 60
3 else if (逾期天数 <= 90) then 75
4 else 100
5 endif
6 endif
7 endif
          
```

- 以“拖欠金额得分 * 0.4 + 拖欠时间得分 * 0.6”获得拖欠总得分，然后进行打分变成离散变量。

拖欠总得分

导出为: 公式

字段类型: <缺省>

公式:

1 拖欠金额得分 * 0.4 + 拖欠时间得分 * 0.6

拖欠总得分离散值

导出为: 公式

字段类型: <缺省>

公式:

1 if (拖欠总得分 <= 60) then '轻度拖欠'
2 else if (拖欠总得分 <= 75) then '中度拖欠'
3 else '重度拖欠'
4 endif
5 endif

- 另外，根据客户信息中的居住情况数据定义“房产”变量，内容为“有房”或“无房”。

房产

导出为: 公式

字段类型: <缺省>

公式:


1 if (居住类型 = '自购房') then '有房'
2 else if (居住类型 = '租房') then '无房'
3 else '无房'
4 endif
5 endif

确定 取消 应用(A) 重置(R)

- 合并后，选择离散的拖欠得分情况为目标变量，选择个人用户特征的变量，如：年龄、性别、婚姻、收入等，作为输入变量。

拖欠总得分离散值	名义	中度拖欠 轻度拖欠 重度拖欠	无	目标
性别	标记	男女	无	输入
年龄_连续	连续	[19.0,70.0]	无	输入
婚姻状态	名义	已婚 未婚 离异	无	输入
户籍	名义	上海 内蒙古 北京 吉林 四川 天津...	无	输入
教育程度	名义	初中及以下 大专 本科 硕士 及以...	无	输入
职业类别	名义	个体户 其他企业 国有企业 外资...	无	输入
工作年限	连续	[0.0,50.0]	无	输入
个人收入_连续	连续	[11230.0,9.9E10]	无	输入
保险缴纳	标记	有无	无	输入
车辆情况	标记	有无	无	输入
房产	标记	有房 无房	无	输入


- 调用C5.0模型，得到如下结果：可以看到户籍和收入对于是否发生拖欠最为重要，其次是保险和职业情况。



5.4 基于聚类分析客户特征

在前面使用了众多的关联分析，为了获得更加多样的分析和比较，此处我们使用聚类分析的方法对顾客消费记录数据中的特征进行进一步的分析。

➤ 主要流程如下：




➤ 首先，审核数据质量，我们分析变量的完整性和数据的分布特点，我们使用“数据审核”节点；如图所示，特征并不呈现良好的正态分布，特别是个人收入，其差异性较大，标准差也非常大。

字段	样本图形	测量	最小值	最大值	平均值	标准差	偏度	唯一	有效
日均消...		连续	30.000	81797.000	8588.844	19410.212	2.851	--	5954
日均次数		连续	1.000	28.000	3.017	2.139	3.256	--	5954
单笔消...		连续	1.500	6052.300	767.326	1520.346	2.390	--	5954
单笔消...		连续	30.300	500000.000	32985.127	61030.249	5.663	--	5954
个人收...		连续	10416.000	99000000000.000	58940691.965	2226598764.237	44.241	--	5954

- 其次，点击质量选项，查看发现数据质量情况良好，没有缺失、空值、空白值的情况，为后续分析做好铺垫。

完整字段(%): 100%										完整记录(%): 100%									
操作	缺失插补		方法	完成百分比	有效记录		空值	字符型空值		空白	空白值								
	从不	固定		100	5954		0	0	0	0	0								
	从不	固定		100	5954		0	0	0	0	0								
	从不	固定		100	5954		0	0	0	0	0								
	从不	固定		100	5954		0	0	0	0	0								
	从不	固定		100	5954		0	0	0	0	0								

- 使用图形表中的散点矩阵图，输入变量为日均金额、日均次数、单次消费最大消费金额和单次消费最小金额，并用“是否出现欺诈”进行标记，大的圆表示欺诈，小的圆表示未欺诈。



- 可以看到出现明显的聚类效应，例如日均消费金额较低的顾客欺诈的情况更多。

单笔最小消费金额和日均消费金额的散点图中，有一定的线性关系，即单笔消费金额越高则日均消费金额也越高，且可以看到当两者都高到一定程度时（右上角），没有欺诈的出现。


单笔消费最大金额和日均消费中，随着日均消费的增加，单笔消费最大金额出现先慢后快的形式，且可以看到当两者都较高时，很少出现欺诈情况。

日均消费次数和单笔最小消费金额主要分布在靠近x和y轴的区域，呈现“L”形，体

现了一种“二者不可兼得”的趋势，即日均次数较高时，单笔最小金额较低，反之亦然。

单笔最大消费金额和最小消费金额之间体现了一种反“L”形，即刚开始随着最大金额的增长，最小金额增长较快，之后最小金额增长较慢，且欺诈主要发生于最大金额值较低的阶段。

总的来看，日均消费金额、单笔最大消费金额、单笔最小消费金额具有较好的分类效果。




➤ 使用自动聚类，根据下方分析结果可以看到三个经典模型的大体情况，分别是kohonen、k-means和两步模型。接下来要进行细致查看。

是否存在欺诈


是否使...	图形	模型	构建时间 (分钟)	轮廓	聚类 数	最小 聚类 (N)	最小 聚类 (%)	最大 聚类 (N)	最大 聚类 (%)	最小/ 最大	重要性
☒		两步 1	< 1	0.887	2	205	11	1610	88	0.127	0.0
☐		K-m...	< 1	0.846	5	3	0	1601	88	0.002	0.0
☐		Koh...	< 1	0.448	11	5	0	525	28	0.010	0.0

➤ 在 k-means 中，将之前分析的这四个变量作为输入，调用专家模式，聚类为 5，运行结果如下：可以看到模型聚类质量较高，轮廓测量值达到 0.8 左右，评分“良好”；而五个聚类中，最大的居然快到 90%

左右，最小的将近 0.1%，非常不合理；进一步查看发现（下第三张图），是因为单笔最大和最小消费金额以及日均消费金额的重要性差不多。




➤ 因此，我们重新设定聚类数量为 2，并运行，发现聚类质量高达 0.9。并且，根据两个聚类区块的分析图可以知道：大约 90%的客户单笔最大消费金额平均在 2 万元，单笔最小金额平均为 300 元，日均消费金额为 2500 左右，可以看做一般客户；而其他的 10%可以认为是优质客户。




- 通过聚类比较界面，查看两个簇各自变量的比较情况，可以看到两个聚类的最大金额、最小金额和日均消费均有较大差异，唯独日均次数没有什么差异，说明日均次数的重要性不大。


聚类比较




- 为了进一步分析这三个最为重要的变量的关系，我们使用图形版中散点图依次将三者表现出来：单笔消费最小金额低于 4200 且日均消费低于 10000 左右的用户可以形成聚类 A；单笔最小金额超过 4200 且日均消费超过 58000 的客户形成聚类 B；且当单笔最小金额低于 1000 时有极大概率出现欺诈，需要特别注意，而当日均消费高于 70000 时没有欺诈发生，这类客户是极其优质的客户。



- 日均消费低于 11000 且单笔最大小于 170000 为一个聚类 C；日均消费高于 58000 的为一个聚类 D；可以看到 C 中绝大多数发生欺诈,这是劣质客户,是需要防范的;而在 D 类中,只要单笔最大高于 100000,就没有欺诈,此为非常优质的客户。



- 最后将这三个变量用三维散点图表示,可以更为直观感受分布的情况:



四、实验总结

- 1、问题：合并“申请客户信息”和“客户信用记录”两个表格时未保留申请未成功用户信息
解决措施：合并时选中“包含匹配与不匹配记录”
- 2、问题：填充时数据报错，无法填充数据
解决措施：替换值加英文双引号
- 3、问题：SPSS Statistics 和 SPSS Modeler 分别可以进行哪些操作不清晰
解决措施：上网查找具体操作用哪个软件
- 4、问题：年收入显示为“无类型”无法进行后续计算

解决措施：上网查找解决办法，修改名义字段的最大成员数



5、问题：如何用“选择”节点，来使没有欺诈的情况降低到原来的 20%

解决措施：上网查询 IBM spss 官网后学习使用方法



6、问题：如何用“平衡”记录选项来使得未欺诈的数量下降到原来 20%

解决办法：在 CSDN 搜索，学习了具体自定义方法来筛选数据



7、问题：如何使用散点图矩阵时设置标记变量

解决办法：首先网上查询，但发现都是 spss statistics 的方法，但是两者具有相似点，通过借鉴，以及思考标记的目的和表现是什么，例如我们需要一个标记变量，使我们知道哪些是欺诈的，哪些是未欺诈的，接着就想到用大小不同来体现，那么便知道通过设置点的大小根据是否欺诈进行变换。

